



Универзитет „Св. Кирил и Методиј“ во Скопје
**ФАКУЛТЕТ ЗА ИНФОРМАТИЧКИ НАУКИ И
КОМПЈУТЕРСКО ИНЖЕНЕРСТВО**

Дипломски труд

Тема:

**Интелигентно управување со електрична енергија
базирано на длабоко учење со поттикнување**

Ментор:
Проф. д-р Соња Гиевска

Изработил:
Благица Јанческа, 211123

Скопје, 2025

Содржина

Апстракт	3
1. Вовед	4
2. Сродни истражувања	6
3. Опис на системот, методите и експериментот	7
3.1. Опис на симулациската околина CityLearn	7
3.2. Податоци во CityLearn	8
3.2.1. Конфигурациски параметри (schema.json)	8
3.2.1. Проксимално оптимизирање на политики (PPO)	9
3.2.2. Long Short-Term Memory (LSTM)	10
3.2.3. Графички невронски мрежи (GNN)	11
3.2.4. Наградни функции	14
3.4.1. Параметри и услови на експериментот	15
4. Резултати	17
4.1. Евалуциони мерки	18
4.1.2. Метрики за евалуација на невидени згради	18
4.2. Резултати од обука	19
4.2.1. PPO-LSTM-GNN со CustomReward	19
4.2.2. PPO-LSTM-GNN со SimpleReward	20
4.2.3. PPO-LSTM без GNN со CustomReward	20
4.2.4. PPO-LSTM со GNN модул (статички граф) тренинг на 500000 timesteps 21	
4.2.5. PPO-LSTM со GNN (динамички граф) тренинг на 500000 timesteps	22
4.3. Резултати од евалуацијата на невидени згради	22
4.4. Дискусија	24
5. Насоки за идни проширувања	26
6. Заклучок	26
7. Користена литература	28

Апстракт

Овој труд разгледува интелигентно управување со батерии во повеќезградна енергетска мрежа преку засилено учење (Reinforcement Learning). Се споредуваат два пристапи: модел со графски невронски мрежи (GNN) и модел без GNN, како и две наградни функции – комплексна што ги вклучува цената на енергијата, состојбата на батеријата и производството, и поедноставна заснована само на потрошувачка и соларна генерација. Експериментите во симулациската околина CityLearn (15.000 чекори) покажуваат дека GNN овозможува постабилен тренинг, но без подобрување во генерализацијата за овој период. Дополнително, изборот на наградна функција има поголемо влијание врз ефикасноста и стабилноста на агентот, при што комплексната функција води кон поекономични стратегии, а поедноставната само кон базично намалување на потрошувачката.

1. Вовед

Современите енергетски системи се соочуваат со сериозни предизвици поради брзата урбанизација и зголемената потрошувачка на електрична енергија, што го зголемува притисокот врз досегашните дистрибутивни мрежи. Во 2024 година, обновливите извори и нуклеарната енергија сочинуваат близу 40% од вкупното глобално производство, што ја нагласува брзината на енергетската транзиција и предизвиците во интеграцијата на нестабилните извори. Со цел да се обезбеди стабилност и ефикасност, потребни се нови интелигентни методи за управување.

Во оваа насока, учењето со поттикнување (Reinforcement Learning – RL) се наметнува како особено ветувачки пристап. Наместо да се потпира на однапред дефинирани правила, RL им овозможува на агентите да учат преку интеракција со околината и да развиваат стратегии што водат кон намалување на потрошувачката, поефикасно искористување на складираната енергија и намалување на трошоците. Потенцијалот на ваквиот пристап е голем: тој овозможува создавање на системи кои не само што реагираат на тековните услови, туку и предвидуваат идни сценарија, со што придонесуваат кон стабилноста и ефикасноста на целата мрежа.

Еден од клучните предизвици во оваа област е како да се моделираат сложените односи меѓу елементите на енергетската мрежа. Зградите во една урбана заедница не функционираат изолирано – тие се меѓусебно поврзани преку потрошувачката, складирањето и производството на енергија. Графичките невронски мрежи (Graph Neural Networks – GNN) се појавуваат како алатка која овозможува да се искористи оваа поврзаност, преку моделирање на структурните релации и пренесување на информации меѓу различните делови на системот. Комбинацијата на RL и GNN отвора нови можности за развој на агенти кои учат не само од сопствените состојби, туку и од контекстот на мрежата во која се наоѓаат.

Во исто време, повеќеагентските пристапи во управувањето со енергија на згради покажуваат дека координацијата и распределбата на ресурсите може да донесат значителни придобивки во однос на стабилноста и ефикасноста на дистрибутивната мрежа. Во таа насока, современите истражувања активно експериментираат со архитектури кои комбинираат различни методи, а изборот на наградната функција се потврдува како пресуден фактор кој го насочува однесувањето на агентите.

Во рамки на овој труд се разгледува токму оваа проблематика преку симулации во околината CityLearn, каде што се споредуваат агенти со различна архитектура и различно дефинирани награди. Особено внимание се посветува на споредбата помеѓу PPO+LSTM агенти и агенти со GNN компоненти, влијанието на поедноставни наспроти покомплексни наградни функции и видот на графот. На овој начин, истражувањето придонесува за подобро разбирање на тоа како изборот на архитектура и дизајн на награда влијаат врз стабилноста на тренингот и способноста за генерализација, што е од суштинско значење за развој на идни интелигентни системи за управување со енергија. Изворниот код и дополнителната документација за изработката на овој труд се достапни на GitHub: <https://github.com/blagica9/CityLearnPPOAgent>

2. Сродни истражувања

Истражувањата за комбинирање на графички методи со учење со поттикнување ја нагласуваат важноста на ваквиот пристап при моделирање и оптимизација на комплексни системи. Основен труд во оваа област е прегледната студија на Hassouna et al. ^[1], каде што се анализира примената на граф засилено учење во електроенергетските мрежи. Авторите дискутираат како графовите овозможуваат природен начин за репрезентација на поврзаноста и интеракцијата помеѓу различни елементи во мрежата, при што се прикажани методи кои ја зголемуваат стабилноста и ефикасноста на електроенергетските системи. Овој труд претставува значаен теоретски темел за понатамошна примена на графичките невронски мрежи во комбинација со засилено учење.

Понатамошен придонес дава Nie et al. ^[2], кои презентираат сеопфатен преглед на алгоритмите за засилено учење на графови. Во нивната анализа се опфатени техники кои комбинираат различни архитектури на графички невронски мрежи со алгоритми на засилено учење, при што се дискутира нивната примена во динамични и неструктурирани средини. Важноста на овој труд лежи во обезбедувањето на поширока перспектива за тоа како графичките структури можат да придонесат за решавање на задачи со висока комплексност и голем број на состојби, што е особено релевантно за управување со енергетски системи.

Практична примена на овие концепти е прикажана во трудот на Pigott et al. ^[3], каде што е претставен системот GridLearn. Овој систем користи мултиагентно учење со поттикнување за регулација на напонот во дистрибутивна мрежа, преку управување со „behind-the-meter“ ресурси на ниво на згради. Резултатите покажуваат значајно намалување на пренапоните (околу 34%) и подобрување на стабилноста на мрежата, што ја демонстрира практичната вредност на интегрирањето на учење со поттикнување во реални енергетски апликации.


Овие трудови заеднички потврдуваат дека графичките модели и учењето со поттикнување се надополнуваат во процесот на моделирање и оптимизација на енергетски системи, обезбедувајќи и теоретска рамка и практични решенија за современи предизвици во управувањето со енергија.

3. Опис на системот, методите и експериментот

3.1. Опис на симулациската околина CityLearn

CityLearn претставува современа симулациска околина специјално развиена за истражување и евалуација на алгоритми за управување со енергија во повеќезградни заедници. Нејзината главна цел е да обезбеди стандарден и транспарентен начин за споредба на различни методи, особено на алгоритми за учење со поттикнување, во услови што се доволно комплексни и слични на **реалните енергетски мрежи**. На тој начин, CityLearn овозможува развој на интелигентни агенти кои можат да донесуваат одлуки со цел подобро искористување на енергетските ресурси и намалување на оптоварувањето на дистрибутивната мрежа.

Системот е организиран околу **множество згради**, секоја со свои карактеристики, ресурси и профили за потрошувачка и производство. Вообичаено, секоја зграда располага со **соларни панели** како обновлив извор на енергија, **батерија** за складирање на вишокот или за користење во периоди на висока побарувачка, како и уреди за греење, ладење и топла вода. Ваквата конфигурација овозможува моделирање на реални урбани заедници, каде што однесувањето на една зграда може индиректно да влијае на другите преку мрежата.



Слика1: Шематски приказ на поединечна зграда во CityLearn со соларен панел, батерија, HVAC уреди и контролен агент.

Една од најголемите предности на CityLearn е тоа што ја поддржува и **централизираната и децентрализираната контрола**. Во централизираниот случај, еден агент управува со сите згради, додека во децентрализираната поставка секоја зграда има свој агент кој донесува одлуки независно, но сепак е дел од поголема енергетска заедница. Ваквата флексибилност овозможува да се испитуваат различни стратегии за координација, комуникација и распределба на ресурси.

3.2. Податоци во CityLearn

Building_1.csv	30.6.2025 14:35	Microsoft Office E...	441 KB
Building_2.csv	30.6.2025 14:36	Microsoft Office E...	444 KB
Building_3.csv	30.6.2025 14:36	Microsoft Office E...	444 KB
Building_4.csv	30.6.2025 14:36	Microsoft Office E...	455 KB
Building_5.csv	30.6.2025 14:37	Microsoft Office E...	443 KB
carbon_intensity.csv	30.6.2025 14:37	Microsoft Office E...	169 KB
pricing.csv	30.6.2025 14:37	Microsoft Office E...	166 KB
schema.json	30.6.2025 14:25	JetBrains WebStorm	9 KB
weather.csv	30.6.2025 14:37	Microsoft Office E...	675 KB

Во CityLearn секое сценарио е дефинирано преку повеќе датотеки кои содржат временски серии и мета-податоци за зградите и околината. На *Слика 2* се прикажани главните датотеки за сценариото Phase 1:

Слика2: Структура на датотеки за податоците во CityLearn за Phase 1 2022

- **Building_1.csv ... Building_5.csv** – датотеки со часовни временски серии за секоја поединечна зграда. Секој ред претставува еден час во текот на годината, а колоните вклучуваат информации како внатрешна температура, релативна влажност, електрична потрошувачка на опрема, побарувачка за греење/ладење, потрошувачка за санитарна топла вода и соларна генерација.
- **carbon_intensity.csv** – податоци за јаглородната интензивност на електричната енергија, односно количината CO₂ што се емитира по произведен kWh.
- **pricing.csv** – динамички тарифи за електрична енергија, кои се менуваат во текот на денот и ја моделираат економската димензија на управувањето.
- **weather.csv** – временски услови (надворешна температура, влажност, сончева радијација и други климатски фактори) кои директно влијаат врз побарувачката и производството на енергија.
- **schema.json** – конфигурациска датотека што ја опишува структурата на податоците и поврзаноста меѓу различните ресурси во сценариото.

3.2.1. Конфигурациски параметри (schema.json)

Покрај CSV датотеките, секое сценарио во CityLearn има и конфигурациски фајл schema.json кој ја дефинира структурната поставеност на зградите и ресурсите. Тука се опишуваат параметрите за соларни панели, HVAC системи и батерии. Особено важен сегмент е моделот на батеријата, кој содржи:

- **battery_capacity** – вкупен капацитет на батеријата (kWh),
- **battery_power_capacity** – максимална моќност на полнење/празнење (kW),
- **battery_efficiency** – ефикасност на циклусите на полнење и празнење,
- **battery_loss** – загуби при складирање на енергија.

Во текот на симулацијата, батеријата динамички се менува според акциите што ги извршува RL агентот. На секој временски чекор агентот добива набљудување за моменталната состојба на наполнетост (State of Charge – SOC) и носи одлука дали батеријата ќе се полни, празни или ќе остане непроменета. На овој начин батеријата претставува клучен елемент преку кој агентот учи да оптимизира користење на енергијата и да ја намали зависноста од мрежата.

Со својата структура и богат сет на податоци, CityLearn претставува идеална основа за експериментирање со различни архитектури на агенти и дизајни на наградни функции. Оваа околина е веќе препознаена и искористена во современи истражувања за управување со енергија, вклучувајќи и трудот на Pigott et al. ^[3], каде што CityLearn е проширен во системот GridLearn за интегрирање на power-flow модели во дистрибутивната мрежа. Ова потврдува дека CityLearn е соодветен избор за тестирање на напредни RL пристапи во контекст на паметни згради и повеќезградни заедници.

3.3. Методи

3.2.1 Проксимално оптимизирање на политики (PPO)

Proximal Policy Optimization (PPO) е еден од најчесто користените алгоритми во областа на засиленото учење, познат по својата стабилност и ефикасност. Тој припаѓа на групата **policy gradient методи**, чија основна цел е да се оптимизира **политиката** на агентот. Политиката претставува стратегија која дефинира како агентот ќе се однесува во дадена состојба – односно која акција ќе ја избере. Формално, политиката $\pi(a|s)$ ја претставува веројатноста да се избере акцијата a во состојба s . Таа може да биде детерминистичка (една состојба $\rightarrow$ една акција) или стохастичка (една состојба $\rightarrow$ распределба на веројатности за повеќе акции).

Во засиленото учење, целта е да се најде политика што ќе ја максимизира кумулативната награда низ времето. Основниот пристап на policy gradient методите е да се ажурираат параметрите на политиката во насока на градиентот на очекуваната награда. PPO го задржува овој принцип, но воведува механизам за стабилизација на процесот на учење.

Главниот предизвик кај класичните policy gradient методи е што преголеми промени во политиката можат да доведат до нестабилност и губење на претходно наученото. PPO го решава овој проблем со воведување на т.н. **clipped objective**, кој ја ограничува големината на промената. На овој начин, ажурирањата на политиката се прават постепено, што обезбедува сигурно подобрување во текот на тренингот.

Основната формула за PPO е:

$$L^{CLIP}(\theta) = \mathbb{E}_t \left[\min (r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t) \right]$$

каде $r_t(\theta)$ е односот меѓу новата и старата политика, $\hat{A}_t$ е проценетиот advantage (мерка за тоа колку е добра акцијата во дадената состојба), а ϵ е хиперпараметар кој ја контролира дозволената промена. Со оваа функција PPO спречува нагли отскокнувања, но сепак овозможува доволно големи чекори за да се постигне напредок.

Дополнително, PPO се комбинира со value функција, која служи за процена на идните награди, и со ентрописки бонус кој ја стимулира експлорацијата на нови стратегии. Оваа комбинација обезбедува рамнотежа меѓу експлоатацијата на веќе наученото и истражувањето на нови можности.

Поради овие својства, PPO е особено соодветен за апликации во динамични и комплексни системи. Во рамки на ова истражување, PPO се користи за управување со батеријата во повеќезградна заедница, каде што политиката на агентот одредува во секој временски чекор дали батеријата ќе се полни, празни или ќе остане непроменета. Овој пристап овозможува стабилно учење и донесување одлуки кои придонесуваат за намалување на трошоците за енергија и подобро искористување на достапните ресурси.

3.2.2. Long Short-Term Memory (LSTM)

Во ова истражување, како составен дел од архитектурата на агентот е интегрирана **Long Short-Term Memory (LSTM)** мрежа. LSTM е специјализиран тип на рекурентна невронска мрежа развиен со цел да обработува секвенцијални податоци и да се справи со проблемот на исчезнувачки или експлодирачки градиенти, кој е често присутен кај класичните RNN. Нејзината основна предност е способноста да задржува информации релевантни за подолги временски интервали, додека непотребните информации се елиминираат преку механизмот на т.н. врати (input, forget и output gates).

Функцијата на LSTM во рамките на овој проект е да ја моделира временската динамика на енергетските податоци. Потрошувачката на електрична енергија, состојбата на наполнетост на батеријата и цените на електричната енергија не се независни од минатите состојби, туку се развиваат во одредени шаблони низ часови, денови и сезони. Податоците во CityLearn ја отсликуваат оваа реалност и содржат очигледни сезонски варијации: на пример, поголема потрошувачка во зимскиот период поради греење или зголемено производство на соларна енергија во лето. Овие карактеристики ја прават задачата покомплексна и ја нагласуваат потребата од модел што може да препознае и да искористи долгорочни обрасци.

Во имплементацијата, за секоја зграда се користи временски прозорец од 12 часови кој се обновува со секој нов чекор. Овој прозорец содржи низа од последните состојби на зградата и се внесува во LSTM мрежата. На тој начин, агентот не се потпира исклучиво на моменталната состојба, туку има и краткорочна историја која ја збогатува неговата способност за носење одлуки.

Излезот од LSTM претставува компресирана временска репрезентација која ги отсликува релевантните шаблони од податоците. Таа потоа се комбинира со структурните информации добиени од графичката невронска мрежа (GNN), со што се создава вектор што содржи и временска и структурна перспектива. Овој вектор се користи од страна на PPO алгоритмот за да се донесат оптимални одлуки за управување со батеријата.

Со оваа интеграција, LSTM обезбедува моделот да ја зема предвид историската динамика на системот, сезонските трендови и повторливите промени, што резултира со поефикасни и поробустни стратегии за управување со енергија.

3.2.3. Графички невронски мрежи (GNN)

Зградите во енергетска заедница не функционираат изолирано – нивното однесување е поврзано преку заедничката електрична мрежа, временските услови и динамиката на потрошувачката. Игнорирањето на овие односи може да доведе до стратегии што се оптимални само на ниво на поединечна зграда, но не и за целата заедница. Со цел да се искористи оваа меѓусебна зависност, во архитектурата на агентот се интегрираат **Graph Neural Networks (GNN)**, кои овозможуваат учење врз основа на графички структури.

Во графичката репрезентација, **јазлите** претставуваат згради, а **ребрата** претставуваат релации или сличности меѓу нив. Секој јазол содржи вектор на карактеристики (на пример: нето-потрошувачка, соларна генерација и состојба на батерија), а преку GNN тие карактеристики се збогатуваат со информации од соседите. Во ова истражување се користи **Graph Attention Network (GATv2)**, кој динамички учи колку внимание да се посвети на секој сосед, со што се добива пофлексибилна репрезентација на секоја зграда.

- **Статички граф**

Првиот пристап користи **статички граф**, кој се конструира еднаш пред почетокот на тренирањето и останува непроменет до крај. За изградба на графот се користат историски податоци за секоја зграда: нето-потрошувачка, соларна генерација и SOC. Податоците се обработуваат во временски опашки од 24 часа и се стандардираат, по што се пресметува **корелациска матрица** меѓу сите парови згради. За секоја зграда се

избираат најкорелираните соседи според k-Nearest Neighbors (k-NN), а за дополнителна стабилност се користи услов за меѓусебна поврзаност (mutual k-NN). Тежините на ребрата се пропорционални на степенот на корелација.

Овој пристап создава **фиксна структура** која го задржува истиот сет на врски во текот на целиот тренинг. Тоа овозможува стабилно учење и намалена варијабилност, но го ограничува моделот да се адаптира на краткорочни промени во податоците.

```
def build_static_graph_CORR_MUTUAL(env, k=2, hist=24):
    import numpy as np, torch
    def tail_pad(xs, T):
        xs = np.array(xs, dtype=float)
        if xs.size == 0: return np.zeros(T, dtype=float)
        if xs.size >= T: return xs[-T:]
        return np.concatenate([xs, np.full(T - xs.size, xs[-1], dtype=float)])
    n = len(env.buildings)
    nets, sols, socs = [], [], []
    for b in env.buildings:
        nets.append(tail_pad(b.net_electricity_consumption, hist))
        sols.append(tail_pad(b.solar_generation, hist))
        socs.append(tail_pad(b.electrical_storage_soc, hist))
    X = np.concatenate([np.stack(nets, 0), np.stack(sols, 0), np.stack(socs, 0)], axis=1)
    X = StandardScaler().fit_transform(X)
    C = np.corrcoef(X)
    S = np.clip(C, 0.0, 1.0)
    knn = []
    for i in range(n):
        order = np.argsort(-S[i])
        neigh = [j for j in order if j != i][:k]
        knn.append(neigh)
    def mutual(i, j): return (i in knn[j]) and (j in knn[i])
    edge_index, edge_attr = [], []
    for i in range(n):
        for j in knn[i]:
            if mutual(i, j):
                w = float(S[i, j])
                edge_index += [[i, j], [j, i]]
                edge_attr += [[w], [w]]
    feats = []
    for i in range(n):
        feats.append([float(np.mean(nets[i])), float(np.mean(sols[i])), float(np.mean(socs[i]))])
    feats = torch.tensor(np.array(feats), dtype=torch.float32)
    edge_index = torch.tensor(edge_index).T.long() if len(edge_index) else torch.empty((2,0), dtype=torch.long)
    edge_attr = torch.tensor(edge_attr).float() if len(edge_attr) else torch.empty((0,1), dtype=torch.float32)
    return feats, edge_index, edge_attr
```

Слика 3: Имплементација на статички граф со mutual k-NN (функција `build_static_graph_CORR_MUTUAL`)

- **Динамички граф**

Вториот пристап користи **динамички граф**, кој се ажурира периодично за време на тренирањето. Наместо однапред дефинирана структура, топологијата се пресметува според моменталните состојби на зградите. Се земаат последните вредности на нето-потрошувачката, соларната генерација и SOC, кои се стандардираат и се користат за пресметка на евклидови растојанија. Секоја зграда се поврзува со своите најблиски соседи (k-NN), а тежините на ребрата се обратно пропорционални на растојанието.

Овој граф може да се освежува на секој ресет на околината или на одредени интервали (на пример, на секои 24 часа симулациско време). Со тоа, топологијата ја следи динамиката на системот, овозможувајќи агентот да учи и од тековните услови во

заедницата. Предноста е поголема адаптивност и подобра реакција на променливи услови, но недостаток е зголемена варијабилност и потенцијална нестабилност доколку графот се ажурира премногу често.

```
def build_dynamic_graph(env, k=2):
    n = len(env.buildings)
    feats = []
    for b in env.buildings:
        feats.append([
            b.net_electricity_consumption[-1],
            b.solar_generation[-1],
            b.electrical_storage_soc[-1]
        ])
    features = np.array(feats, dtype=np.float32)
    features = StandardScaler().fit_transform(features)
    dists = euclidean_distances(features)

    edge_index, edge_attr = [], []
    for i in range(n):
        nearest = np.argsort(dists[i])[1:k+1]
        for j in nearest:
            w = 1.0 / (dists[i][j] + 1e-6)
            edge_index += [[i, j], [j, i]]
            edge_attr += [[w], [w]]

    ei = torch.tensor(edge_index, dtype=torch.long).T if len(edge_index) else torch.empty((2,0), dtype=torch.long)
    ea = torch.tensor(edge_attr, dtype=torch.float32) if len(edge_attr) else torch.empty((0,1), dtype=torch.float32)
    return torch.tensor(features, dtype=torch.float32), ei, ea
```

Слика 4: Имплементација на динамички граф со евклидови растојанија (функција `build_dynamic_graph`)

- Споредба на графовите

Карактеристика	Статички граф	Динамички граф
Критериум за врски	Корелација на историски податоци (mutual k-NN)	Евклидово растојание на моментални податоци
Временска стабилност	Срцките се фиксни за време на целиот тренинг	Врските се ажурираат периодично
Адаптивност	Ограничена – не реагиран а промени	Висока – ја следи моменталната состојба
Предност	Стабилно учење, помала варијабилност	Подобра реакција на динамички услови
Недостаток	Може да игнорира краткорочни трендови	Поголема варијабилност и чувствителност кон шум

Табела 1: Споредба на графовите

Со комбинирање на GNN со статички и динамички графови, моделот добива способност да ги искористи и **структурните односи** меѓу зградите и **временските шаблони** преку LSTM. Статичкиот граф овозможува стабилност, додека динамичкиот внесува адаптивност и ја збогатува репрезентацијата со актуелни информации. Ваквата

поставка овозможува сеопфатна анализа на придобивките и предизвиците на двата пристапа во управување со енергија во повеќезградни заедници.

3.2.4. Наградни функции

Дизајнот на наградната функција претставува еден од најкритичните аспекти во рамките на засиленото учење, бидејќи токму преку неа агентот добива повратна информација за квалитетот на своите акции. Преку акумулирање на награди, политиката што ја учи алгоритмот се насочува кон стратегии кои максимизираат долгорочна добивка. Кај алгоритмот Proximal Policy Optimization (PPO), наградата има централна улога во стабилноста и ефикасноста на учењето, бидејќи ја обликува распределбата на политиката и го дефинира балансот меѓу експлорација и експлоатација ^[1].

Поради тоа, внимателното дефинирање на наградните функции е особено значајно во апликации за енергетски системи, каде што целите честопати се мулти-објективни и вклучуваат минимизација на трошоци, максимизација на искористување на обновливи извори и обезбедување на стабилност на мрежата ^[3].

Во рамки на ова истражување се дефинирани и споредени две наградни функции – **SimpleReward** и **CustomReward** – кои се разликуваат според комплексноста и бројот на фактори што ги земаат предвид.

- **SimpleReward**

Функцијата **SimpleReward** има за цел да обезбеди основен сигнал за учење преку неколку интуитивни компоненти. Првата компонента се однесува на минимизација на нето-потрошувачката на електрична енергија. Наградата се дефинира како негативна вредност на купената енергија, што го охрабрува агентот да ја намали зависноста од мрежата или да продава енергија кога е тоа можно. Втората компонента додава позитивен поттик за искористување на соларната енергија, со што се нагласува важноста на локалното производство од обновливи извори.

Дополнително, во рамки на функцијата е интегрирано управување со батеријата преку неколку правила. Се предвидува казна доколку батеријата е празна во услови на висока потрошувачка, како и доколку е преполна во период на соларна генерација, кога постои ризик од губење на енергија. Се доделува мала награда за рационално користење на батеријата кога потрошувачката е висока, како и мала казна за значително отстапување од оптималната состојба на полнење околу 50%. Ваквиот пристап, иако едноставен, обезбедува доволно стабилен сигнал за агентот да развие основни стратегии за енергетска ефикасност ^[2].

- **CustomReward**

Функцијата **CustomReward** претставува понапредна верзија која ја надградува претходната дефиниција со интеграција на економски фактори. Основниот дел од наградата се заснова на минимизација на трошоците за електрична енергија, при што нето-потрошувачката се множи со моменталната цена на електричната енергија. На овој начин, агентот е дополнително мотивиран да избегнува купување енергија во периоди на високи тарифи и да ја користи или продава складираната енергија кога тоа е економски исплатливо.

И во оваа функција е задржан позитивниот поттик за искористување на соларната енергија, како и правилата за управување со батеријата, но тие се дополнети со нови компоненти. Се доделува мала награда за полнење на батеријата кога цената е ниска, што го поттикнува агентот да купува евтино, и мала награда за празнење кога цената е висока, со што се стимулира продажба или користење на складираната енергија во моменти со најголема економска добивка. Дополнително, останува и казната за значително отстапување од оптималното ниво на полнење околу 50%. Со оваа функција, агентот учи понапредни стратегии кои се истовремено енергетски и економски ефикасни. Како што укажува литературата, мулти-објективните наградни функции се неопходни за практична примена на засиленото учење во енергетски системи, бидејќи овозможуваат балансирање на повеќе цели и подобро справување со комплексноста на околината ^[1].

3.4. Експериментална поставеност

За изведување на експериментите беше користено сценариото **Phase 1** од *CityLearn Challenge 2022*. Ова сценарио опфаќа пет згради со различни карактеристики во однос на потрошувачката на електрична енергија, соларната генерација и капацитетот на батеријата. За потребите на ова истражување, агентот беше трениран на **една избрана зграда**, а потоа добиената политика беше евалуирана и на останатите четири згради во рамки на истото сценарио. На тој начин се овозможи проценка на **генерализацијата** на агентот – односно дали стратегијата што ја научил во една зграда може успешно да се пренесе и на други згради со различни профили, но во идентична околина.

3.4.1. Параметри и услови на експериментот

За изведување на експериментите во ова истражување, беше користен **CityLearn Phase 1** сценариото од *CityLearn Challenge 2022*. Ова сценарио вклучува пет згради со различни профили на потрошувачка на електрична енергија, соларна генерација и капацитет на батерија. Агентот беше трениран на една избрана зграда, а потоа евалуиран на преостанатите четири згради со цел да се испита **генерализацијата** на

научената стратегија и нејзината способност да се пренесе на други згради со слични, но различни профили во истата симулациска околина.

- **Интеграција на PPO, LSTM и GNN**

За тренирање на агентите, беше користен **Proximal Policy Optimization (PPO)** алгоритмот, имплементиран преку **Stable Baselines3** библиотеката. PPO беше избран поради неговата стабилност и ефикасност во контекст на континуирани задачи. Алгоритмот го користи **policy gradient** методот за учење на оптимална политика, што значи дека се прават постепени и контролирани ажурирања на политиката на агентот, наместо да се прават големи промени кои можат да ја направат стратегијата нестабилна. Во комбинација со **Generalized Advantage Estimation (GAE)**, PPO обезбедува побрзо и поефикасно учење, додека ја балансира експлорацијата и експлоатацијата.

Во ова истражување, агентот беше дополнително обогатен со **LSTM (Long Short-Term Memory)** и **GNN (Graph Neural Networks)** компоненти, интегрирани за подобро разбирање на временските зависности и графовите на енергетските податоци. Тие беа интегрирани на следниов начин:

- **LSTM:** Користење на **PyTorch** за имплементација на LSTM слоеви, кои овозможуваат агентот да ја запамти краткорочната историја на енергетската потрошувачка и соларната генерација. LSTM мрежата беше користена за справување со временските зависности, што е клучно за задачите каде што потрошувачката и генерацијата на енергија се менуваат низ времето. Секој влез во LSTM моделот беше низа од 12 временски чекори (часови), што овозможи агентот да прави информирани одлуки врз основа на претходните состојби.
- **GNN:** Користење на **PyTorch Geometric** за изградба на графовите кои моделираат меѓусебната зависност помеѓу различни згради во системот. За секоја зграда, градење динамички граф кој се ажурираше по секоја епизода. Врските меѓу зградите беа формирани на основа на **Евклидови растојанија** (euclidean distance) меѓу нивните карактеристики (потрошувачка на енергија, соларна генерација и статус на батеријата). Овие графови беа користени како дополнителен извор на информации за агентот, заедно со временската историја обработена преку LSTM.

Кодот беше имплементиран во **Python** со користење на следниве библиотеки и методи:

- **Stable Baselines3:** за имплементација на PPO и управување со тренинг процесот;
- **PyTorch:** за изградба и тренинг на LSTM мрежата, како и за обработка на графовите преку GNN;
- **PyTorch Geometric:** за создавање и обработка на графовите, користејќи **GATv2Conv** слоеви за подобро учење на зависностите помеѓу зградите.

- **Користени Хиперпараметри**

Сите агенти беа тренирани со идентични хиперпараметри за да се обезбеди фер споредба на резултатите:

- **Стапка на учење (learning rate):** 3×10^{-4} ;
- **Дисконтен фактор (γ):** 0.99;
- **Големина на батч (batch size):** 64;
- **Clip ratio за PPO:** 0.2;
- **GAE λ (Generalized Advantage Estimation):** 0.95;
- **Entropy коефициент:** 0.01, за стимулирање на експлорацијата;
- **Број на чекори по епизода:** 8,760 (една година со часовна резолуција);
- **Број на епизоди за тренирање:** 15,000 или 500 000;
- **Максимална должина на епизода:** една календарска година;
- **Нормализација на наградите:** применета за стабилизирање на учењето;
- **Ресетирање на LSTM состојбите:** на почетокот на секоја епизода, за правилно справување со временските зависимости.

Во текот на тренирањето се користеле различни стратегии за оценка и адаптирање на графовите, како и техники за оптимизација на перформансите. За динамичките графови беше применет **методот на корелација на карактеристики** кој ја користи **корелацијата на податоците** за да создаде адаптивни врски помеѓу зградите, кои се ажурираат во текот на тренингот.

4. Резултати

Врз основа на методологијата и експерименталната поставеност опишани во претходните поглавја, во овој дел се презентираат и анализираат добиените резултати. Целта на експериментите беше да се испита влијанието на архитектурата на агентите (PPO со LSTM и PPO со дополнителна GNN компонента), како и ефектот од различни дефиниции на наградната функција (поедноставна и комплексна). На овој начин се овозможува споредба на две димензии: прво, дали графската репрезентација придонесува за подобри стратегии на управување со енергија, и второ, како изборот на награда го обликува однесувањето на агентот.

Презентацијата на резултатите е организирана во неколку подделови. Најнапред се прикажуваат трендовите на обука преку евалуациони мерки што го следат процесот на учење, потоа се презентираат резултатите од евалуација на невидени згради со цел да се провери генерализацијата на моделите, а на крај следи дискусија и интерпретација на добиените наоди.

4.1. Евалуциони мерки

Евалуацијата во ова истражување е дизајнирана така што овозможува и следење на процесот на учење за време на тренингот, и проверка на способноста на моделите за генерализација на нови ситуации. Со цел да се добие целосна слика за перформансите, беа користени две групи на мерки: **метрики за време на обуката** и **метрики за евалуација на невидени згради**.

4.1.1. Метрики за време на обука

За време на процесот на тренирање се следеа неколку клучни показатели што се извлекуваат директно од PPO алгоритмот:

- **Епизодна вкупна награда (Episode Reward)**: основен индикатор за квалитетот на научената политика на таргет-зградата, пресметан на секој интервал на евалуација.
- **Value Loss**: грешка во предвидувањето на вредносната функција, која укажува колку добро агентот ја проценува идната награда.
- **Policy Loss**: мери како и со кој интензитет се ажурира политиката во текот на учењето.
- **Entropy**: индикатор за степенот на истражување на агентот; повисока ентропија значи поширока разновидност на дејства, додека постепено намалување упатува дека моделот се фокусира на пооптимални стратегии.
- **Explained Variance**: кохерентност помеѓу предвидувањата на вредносната функција и реалните награди; повисока вредност укажува на постабилно и поквалитетно учење.

Овие мерки овозможува да се следи напредокот уште во раните фази на тренингот, без да се чека завршување на целосната обука за да се процени стабилноста и ефикасноста на политиката.

4.1.2. Метрики за евалуација на невидени згради

Втората група метрики се однесува на проценката на способноста на агентите да ја применат научената политика врз згради кои не биле дел од тренинг сетот. Ова е особено важно бидејќи ја мери **генерализацијата** на моделите. Главниот индикатор во оваа фаза е:

- **Вкупна награда (Total Reward)**: акумулирана награда добиена за целосната епизода на тест- зградата.


Процедурата на евалуација подразбира избор на згради што не биле користени во обуката, извршување на целосна епизода со научената политика (без дополнително прилагодување), и снимање на вкупната награда за секоја тест-зграда одделно. На тој начин се обезбеди објективна споредба меѓу архитектурите (GNN vs. No-GNN), различните дизајни на наградни функции (CustomReward vs. SimpleReward) како и различните типови на графови.

4.2. Резултати од обука

Во продолжение се прикажуваат резултатите од обуката на агентите. Фокусот е ставен на динамиката на кумулативната награда во текот на времето, како главен индикатор за процесот на учење. Презентирани се пет различни комбинации на архитектури и наградни функции, при што секој график овозможува увид во стабилноста и ефикасноста на соодветниот агент.

4.2.1. PPO-LSTM-GNN со CustomReward


На Слика 5 е прикажан процесот на обука на агентот кој комбинира Proximal Policy Optimization (PPO) со Long Short-Term Memory (LSTM) и Graph Neural Network (GNN), користејќи ја комплексната наградна функција CustomReward.



Слика 5: Тренд на кумулативната награда при тренирањето на PPO-LSTM-GNN агентот со CustomReward

Кривата ја прикажува еволуцијата на просечната награда низ времето, пресметана на интервали на евалуација.

На почетокот на тренингот наградата има многу ниска вредност, по што следува нагло зголемување во првите неколку илјади чекори. Потоа кривата се стабилизира и останува во опсег од приближно -600 до -800 поени, со помали варијации во одделни интервали. Во подоцнежните чекори се забележува благо намалување на кривата, но таа останува релативно константна до крајот на тренирањето.




Слика 6: Тренд на кумулативната награда при тренирањето на PPO-LSTM-GNN агентот со SimpleReward.

4.2.2. PPO-LSTM-GNN со SimpleReward

На Слика 6 е прикажан процесот на обука на агентот кој комбинира Proximal Policy Optimization (PPO) со Long Short-Term Memory (LSTM) и Graph Neural Network (GNN), користејќи ја поедноставната наградна функција *SimpleReward*. Кривата ја прикажува еволуцијата на просечната награда низ времето, пресметана на интервали на евалуација.

Наградата на почетокот се движи околу -2500 поени, со мало намалување во првите неколку илјади чекори, по што кривата останува релативно стабилна. Во средината на процесот се забележува постепено зголемување на вредностите и достигнување на највисока точка од околу -2200 поени. Потоа следува остар пад кој достигнува до приближно -3800 поени, по што кривата повторно се искачува и постепено се стабилизира кон крајот на тренирањето, останувајќи во опсег меѓу -2700 и -2500 поени.



Слика 7: Тренд на кумулативната награда при тренирањето на PPO-LSTM агентот со CustomReward (без GNN).


4.2.3. PPO-LSTM без GNN со CustomReward

На Слика 7 е прикажан процесот на обука на агентот кој комбинира Proximal Policy Optimization (PPO) со Long Short-Term Memory (LSTM), без интеграција на Graph Neural Network (GNN), користејќи ја комплексната наградна функција *CustomReward*. Кривата ја

прикажува еволуцијата на просечната награда низ времето, пресметана на интервали на евалуација.

На почетокот на тренингот наградата се движи околу -1000 поени, по што следува нагло намалување и достигнување на најниска точка близу -3000 поени. Потоа кривата повторно нагло расте и за кратко време достигнува позитивен тренд, со вредности околу -500 поени. Во понатамошниот тек на тренирањето се забележува стабилизација, при што просечната награда останува во интервал од -1000 до -700 поени, со помали варијации низ епизодите.

4.2.4. PPO-LSTM со GNN модул (статички граф) тренинг на 500000 timesteps




Слика 8: Тренд на кумулативната награда при тренирањето на PPO-LSTM агентот со CustomReward (со GNN) статички граф

Тренингот започнува со **ниски вредности на награда** кога агентот започнува да учи, што е очекувано за почетни фази на учење. Како што агентот продолжува да се обучува, наградата постепено се зголемува, што укажува на тоа дека моделот учи и се адаптира на средината. Сепак, постојат флуктуации во вредноста на наградата, што може да биде предизвикано од различните обиди на агентот да се адаптира на динамиката на енергетскиот систем.

Графикот покажува дека агентот постепено стабилизира своето однесување по извесен број чекори и ја достигнува својата највисока награда при околу 340.000 чекори. Овој момент претставува најдобра евалуација на агентот од досега, што сугерира дека агентот успешно го научил оптималниот начин на управување со енергетските ресурси, во контекст на статистички граф.

Графикот обезбедува визуелна потврда дека агентот е способен да се подобрува во текот на тренингот, со стабилизација на наградите и постигнување најдобри резултати, што е основна цел при примената на **PPO** во сложени енергетски средини.

4.2.5. PPO-LSTM со GNN (динамички граф) тренинг на 500000 timesteps



Слика 9: Тренд на кумулативната награда при тренирањето на PPO-LSTM агентот со CustomReward (со GNN) динамички граф

Тренингот започнува со ниски вредности на награда, што е вообичаено во раната фаза кога агентот учи од својата средина. Како што агентот ги подобрува своите одлуки и ја разбира динамиката на системот, наградата постепено расте, достигнувајќи стабилизација во текот на времето. Во овој тренинг процес, агентот е обучуван со **динамички граф**, што значи дека секој нов временски чекор создава нова мрежа на слични згради, овозможувајќи агентот да ги адаптира своите стратегии врз основа на најновите информации.

Графикот ја потврдува успешноста на агентот во адаптирањето на динамичкиот граф, при што се зголемува стабилноста на наградата низ текот на тренингот. Вредноста на наградата на крајот од тренингот покажува позитивни трендови, што сугерира дека агентот успешно го научил оптималното управување со енергетските ресурси во динамичката средина.

4.3. Резултати од евалуацијата на невидени згради

По завршувањето на фазата на обука, агентите беа евалуирани на згради кои не беа дел од тренингот, со цел да се провери нивната способност за генерализација. Овој пристап овозможува да се утврди дали стратегиите што ги научил моделот можат да се применат и во нови услови, односно дали агентот учи политики што се ограничени на една специфична зграда или успева да најде пошироки решенија применливи и за други случаи.

Во првата серија на експерименти беше изведена споредба меѓу агентите со и без графска компонента (GNN). Резултатите се прикажани во **Табела 2**, каде што за секоја

од преостанатите згради се прикажува акумулираната награда добиена за целосната епизода. Забележливо е дека вредностите се различни за различните згради, што е очекувано поради нивните различни профили на потрошувачка и производство.

Зграда (ID)	Reward (GNN Agent)	Reward(Non-GNN Agent)	Зграда (ID)	Агент со CustomReward	Агент со SimpleReward
1	-903.35	-675.46	1	-903.35	-3076.81
2	-138.21	144.36	2	-138.24	-510.71
3	-625.10	-459.38	3	-625.10	-3660.65
4	-579.69	-319.77	4	-579.69	-1775.88

Табела 2: Резултати од евалуација на невидени згради за PPO-LSTM агенти со SimpleReward и CustomReward.

Табела 3: Резултати од евалуација на невидени згради за PPO-LSTM агенти со и без GNN.

Паралелно со оваа споредба беше направена и анализа на различните наградни функции. **Табела 3** ги прикажува резултатите за SimpleReward и CustomReward функциите, каде што повторно е користен истиот принцип на тестирање врз згради што не биле дел од тренинг сетот. Вредностите покажуваат како изборот на наградна функција влијае врз перформансите на моделот при работа во нови услови.

Ваквиот пристап на евалуација овозможува јасна и транспарентна споредба. Од една страна може да се согледа улогата на графската репрезентација во способноста на агентите да се пренесат на нови згради, а од друга страна се добива увид во тоа колку е важен дизајнот на наградната функција за успехот на стратегиите што се развиваат.

Резултатите од евалуацијата за генерализација на агентите со статички и динамички граф во CityLearn покажуваат мерливи разлики во перформансите на невидени згради. Следната табела ги прикажува точните вредности на акумулирана награда (“Total reward”) за секоја невидена зграда, добиени при тестирање на најдобриот модел по завршена обука, за двете варијанти: со статички и динамички граф.

Архитектура	Building 1	Building 2	Building 3	Building 4
Динамички граф	-911.14	6.29	-885.03	-485.28
Статички граф	-710.01	174.08	-712.01	-254.11

Табела 4: Резултати од евалуација на невидени згради на агентите тренирани со GNN графички и динамички граф

При тестирање на невидени згради, агентот базиран на статички граф покажува значително подобра генерализација кај Building 2, со највисока (и позитивна) вкупна награда од 174.08, и најдобра релативна стабилност и на Building 4.

Динамичкиот граф дава позитивна награда само кај Building 2 (6.29), но на останатите тест згради (1, 3, 4) постигнува значително пониски вредности во споредба со статичкиот граф.

Кај двете варијанти најдобра генерализација се забележува на Building 2 (позитивна вредност), додека најнизок резултат редовно се среќава на Building 1 (најнегативна сумарна награда).

Овие резултати потврдуваат дека во сценариото CityLearn Phase 1 и при дадените хиперпараметри, статичкиот граф води кон подобра генерализација на агентот на невидени згради според акумулираната награда. Динамичката топологија, иако овозможува привремена адаптивност на поврзаноста, може да внесе дополнителна варијабилност, што во крајна инстанца се одразува како поголема нестабилност при тестирање на нови згради. Специфично, статичкиот пристап го стабилизира трансферот на политиката, додека динамичкиот граф во ова ограничено сценарио не носи значајна предност според акумулираната награда.

4.4. Дискусија

Резултатите од спроведените експерименти овозможуваат значаен увид во влијанието на архитектурата на агентите и дизајнот на наградните функции врз ефективноста на интелигентното управување со енергија во повеќезградна мрежа.

Најнапред, анализата на перформансите покажува дека вклучувањето на Graph Neural Networks (GNN) како дел од архитектурата на агентот не доведе до конзистентно подобрување во споредба со агенти што користат само LSTM и PPO без графички модул. Ова може делумно да се објасни со ограниченоста на тестираниот систем, каде што симулациите вклучуваат само пет згради, што можеби не овозможува доволна комплексност и изразени меѓузависности за да се искористи потенцијалот на графските структури. Во поголеми и поповрзани мрежи, каде што интеракциите се поизразени и подинамични, се очекува GNN да ја покаже својата предност преку подобро моделирање и пренесување на информации меѓу јазлите. Ова укажува дека во следните фази од истражувањето треба да се експериментира со посложени сценарија и поголеми мрежи за јасно дефинирање на придобивките од графичките невронски мрежи во управувањето со енергија.

Од друга страна, изборот на наградната функција се покажа како критички фактор за успехот на учењето на агентите. Поедноставната наградна функција (SimpleReward), која се фокусира само на основни енергетски параметри како што се намалувањето на нето-потрошувачката и поттикот за користење на соларна енергија, не обезбеди

доволно силен и информативен сигнал за агентот. Во споредба, комплексната наградна функција (CustomReward), која вклучува и економски аспекти, како варијации во цената на електричната енергија и дополнителни правила за рационално управување со батериите, доведе до посуптилни и поефикасни стратегии. Оваа разлика се рефлектира во повисоките и постабилни вредности на вкупната награда, особено при тестирање на невидени згради, укажувајќи на подобра генерализација и поекономично управување. Ова ја потенцира важноста од внимателно осмислување на наградните функции како мулти-објективни оптимизациони задачи, кои се клучни за практичната примена на засиленото учење во реални енергетски системи.

Во контекст на дизајнот на графските структури, забележано е дека агентите кои користат статички граф покажуваат поголема стабилност и подобра генерализација во споредба со оние што користат динамички графови. Фиксната структура на статичкиот граф овозможува постабилно учење, со помала варијабилност во текот на тренингот и подобро пренесување на научената политика на нови згради. Напротив, динамичкиот граф нуди поголема адаптивност и инкорпорира најнови состојби, но истовремено воведува повисока варијабилност и може да доведе до нестабилност во учењето. Ова сугерира дека при изборот на топологија потребен е внимателен компромис помеѓу стабилност и адаптивност, прилагоден на комплексноста и природата на конкретната енергетска мрежа.

Важно е да се истакнат и ограничувањата на оваа студија. Преку користење на релативно мал број на згради и ограничен период на тренирање во само едно сценарио, не е можно да се извлечат универзални заклучоци за сите видови енергетски системи. Идните истражувања треба да вклучат поголеми и поразнолики мрежи, покомплексни сценарија и подолги тренинг периоди за да се појаснат границите и потенцијалите на различните архитектури и наградни функции. Дополнително, тестирањето на различни типови графски модели и развој на поефикасни наградни функции може дополнително да го подобри учењето и примената.

Од практична гледна точка, резултатите укажуваат дека засиленото учење, особено кога е правилно конфигурирано со адаптивни архитектури и добро осмислени награди, има потенцијал да понуди напредни решенија за интелигентно управување со енергијата во паметни згради и заедници. Иако постојат предизвици во форма на потреба од големи количини податоци и компјутерската ресурсија, овие истражувања поставуваат цврсти темели за развој на поефикасни, економски исплатливи и одржливи енергетски системи во иднина.

5. Насоки за идни проширувања

Врз основа на резултатите, идните истражувања треба да се насочат кон примена на модели на пошироки и посложени мрежи, кои вклучуваат поголем број на згради и пореални релации помеѓу нив. Истражувањето на нови архитектури и развојот на мулти-објективни наградни функции ќе овозможи создавање поефикасни, поробустни агенти. Играњето со механизми за соработка и координација преку мултиагентски и хибридни системи може дополнително да го подобри управувањето. Справувањето со неизвесности и тестирањата во реални услови ќе ја зголемат применливоста на решенијата во практиката.

Исто така, се препорачува истражување на нови архитектурни решенија, како и воведување на мултиагентски и хибридни пристапи, кои би овозможиле подобра координација и соработка меѓу агенти во поголеми мрежи. Справувањето со неизвесностите во податоците преку *robust reinforcement learning* техники и реални тестирања во пилот-проекти ќе го зајакнат практичниот импакт на овие системи. Овие насоки ќе ја збогатат и продлабочат примената на засиленото учење за интелигентно управување со енергија во иднина.

6. Заклучок

Експериментите прикажани во овој труд овозможија систематска анализа на две клучни димензии: архитектурата на агентите и дефиницијата на наградните функции. Спроведените тестирања во сценариото Phase 1 од *CityLearn Challenge 2022* покажаа дека и покрај ограничувањата во бројот на епизоди и опфатот на околината, агентите успеаја да усвојат стратегии кои значајно ја подобруваат нивната ефикасност во управувањето со енергијата.

Резултатите од обуката ја нагласија разликата во динамиката на учење меѓу агенти со и без графска компонента. Иако GNN не покажа конзистентна предност во дадените услови, самата интеграција на графски структури претставува важна насока за идни истражувања, особено во посложени сценарија каде што меѓузависностите меѓу зградите се поизразени.

Од друга страна, јасно беше потврдено дека изборот на наградна функција има клучно влијание врз резултатите. Агентите кои користеа *CustomReward* постигнаа повисоки награди и поголема стабилност при евалуација на невидени згради, што ја истакнува важноста од внимателен и добро осмислен дизајн на наградниот сигнал.

Овој труд, иако ограничен на едно сценарио и релативно краток период на тренирање, демонстрира валиден и успешен пристап за анализа на комбинацијата на архитектури и наградни функции. Постигнатите резултати претставуваат позитивна основа за понатамошна работа и укажуваат дека со проширување на експериментите – преку повеќе сценарија, подолг тренинг и дополнителни модификации на графската репрезентација – може да се постигнат уште поквалитетни и поконзистентни стратегии.

Со ова, може да се заклучи дека истражувањето претставува добра насока во областа на интелегентно управување со енергија. Постигнатите резултати не само што обезбедуваат увид во моменталните предизвици и ограничувања, туку и поставуваат цврста основа врз која може да се гради идно истражување и развој на уште поефикасни агенти.

7. Користена литература

- [1] M. Hassouna, C. Holzhüter, P. Lytaev, J. Thomas, B. Sick, C. Scholz, **Graph Reinforcement Learning for Power Grids: A Comprehensive Survey**, arXiv:2407.04522, 2024. Достапно на: <https://arxiv.org/abs/2407.04522>
- [2] M. Nie, D. Chen, D. Wang, **Reinforcement Learning on Graphs: A Survey**, arXiv:2204.06127, 2023. Достапно на: <https://arxiv.org/pdf/2204.06127>
- [3] Pigott, C. Crozier, K. Baker, Z. Nagy, **GridLearn: Multiagent Reinforcement Learning for Grid-Aware Building Energy Management**, arXiv:2110.06396, 2021. Достапно на: <https://arxiv.org/pdf/2110.0639>
- [4] López-Cardona, A. et al. "Proximal Policy Optimization with Graph Neural Networks for Optimal Power Flow " (2025)
<https://www.scitepress.org/Papers/2025/134627/134627.pdf>
- [5] Multiagent Energy Management System Design Using Reinforcement Learning: The New Energy Lab Training Set Case Study
<https://onlinelibrary.wiley.com/doi/full/10.1155/etep/3574030>